

Progress report

Neurónové siete

Zadanie 3

Hládek Adrián, Filip Remšík

Úvod

V tomto zadaní sa budeme venovať CycleGAN a AMS-CycleGAN. Pre tréning a testovanie modelu budeme využívať existujúci dataset dostupný na

<https://www.kaggle.com/datasets/suyashdamle/cyclegan>

Dáta sme si prezreli a zamerali sme sa na tie ktoré majú len rovnaké rozlíšenie aby sme nemuseli robiť úpravy navyše. Pri prezieraní obrázkov sme zistili že niektoré by bolo vhodné odstrániť nakoľko zvierá na nich nebolo dostatočne viditeľné, avšak ručné čistenie dát by zabralo veľa času.

Postup a komplikácie

Prvým krokom pre vytvorenie modelu bol výber dát, nad ktorými chceme pracovať. Ako alternatívy, ku ktorým sme viac inklinovali boli 2 kategórie.

Predmet<>Predmet

Štýl<>Fotografia

Do kategórie *Predmet<>Predmet* spadajú datasety

Horse<>Zebra

Apple<>Orange.

Do kategórie *Štýl<>Fotografia*

Monet<>Fotografia

Ukiyoe<>Fotografia


Vangogh<>Fotografia

Z prevzatých modelov, ktoré sú voľne k dispozícii sme vytvorili prvotné verzie, kde sme otestovali dané kategórie.


Štýl<>Fotografia

Testovali sme na 200 Epochách pre dataset Ukiyoe a Monet. Napriek tomu že výsledok bol pre prvotné experimenty dosť znateľný. Z praktického hľadiska sme nevideli v týchto datasetoch potenciál, pretože dané umelecké štýly sú skôr abstraktného charakteru. Čo by mohlo byť problém subjektívne určiť či došlo k zlepšeniu modelu.na základe čisto vyzuálnych prvkov.


Real Photo




Fake Monet (Photo -> Monet)




Real Photo




Fake Monet (Photo -> Monet)



Real Monet




Fake Photo (Monet -> Photo)



Real Photo




Fake Monet (Photo -> Monet)





Real Monet







Fake Photo (Monet -> Photo)



Predchádzajúce výsledky sú vytvorené pomocou modelu ***Monet_ukoiey.ipynb***. Prvých 6 obrázkov je výstup príkladov pre dataset Monet, ďalšie 4 sú vytvorené z datasetu Ukoiey. Testovali sme na veľkosti obrázkov 64x64. Vďaka tejto prvotnej analýze sme sa rozhodli sústrediť na dataset Apple<>Orange pre budúce experimenty. Nasledujúce Grafy zobrazujú Loss hodnoty funkcií, môžeme vidieť že krivky značne osciluje čo nieje nečakaný jav pre CycleGan modely v našom prípade až na niekoľko extrémnejších skokov v okolí 90-130 Epochy je klesajúci potenciál pre chybovosť. na datasete Ukoiey sme dosiahli lepšie výsledky, kde tento pokles je lepšie viditeľný.







Apple<>Orange

Tu sme sa zaoberali testovaním na datasete **Apple<>Orange**. Skúšali sme použiť obyčajný CycleGAN a AMS-CycleGAN.


CycleGAN

AMS-CycleGAN - 200 obrázkov, 50 epoch, rozlíšenie 64 x 64


AMS-CycleGAN Output 2



AMS-CycleGAN Output 3




AMS-CycleGAN Output 4




Môžeme vidieť, že model sa naučil že pomaranč je oranžový a darí sa mu aj odstraňovať stopku ale na obrázku 2 a 4 má problémy s obrysom obrázku

AMS-CycleGAN - 200 obrázkov, 5 epoch, rozlíšenie 128 x 128




AMS-CycleGAN - 200 obrázkov,10 epoch, rozlíšenie 128 x 128



AMS-CycleGAN - 200 obrázkov,15 epoch, rozlíšenie 128 x 128

AMS-CycleGAN Output 1




AMS-CycleGAN Output 2



AMS-CycleGAN Output 3



AMS-CycleGAN Output 4



AMS-CycleGAN - 200 obrázkov, 20 epoch, rozlíšenie 128 x 128

AMS-CycleGAN Output 1




AMS-CycleGAN Output 2



AMS-CycleGAN Output 3



AMS-CycleGAN Output 4



Kôň > Zebra

Oproti predchádzajúcim testom sme pridali Resnet bloky a pridali SelfAttention pre lepší prenos štýlu a zachovanie konzistencie, taktiež sme implementovali dropout. Môžeme vidieť

že oproti predchádzajúcim testom sa nám podarilo minimalizovať akoby sieť, ktorá nám rušila obrázok. Taktiež sme použili dropout v reziduálnom bloku.

CycleGAN

Vstupné rozlíšenie 64 x 64, 20 epoch


Sample 1



Sample 2



Sample 3



AMS CycleGAN


64 x 64, 20 epoch



Sample 2



Sample 3




WassersteinGAN

64 x 64, 20 epoch



Input | Output: n02381460_1010.jpg



Input | Output: n02381460_1030.jpg



Accumulated Gradient

Pri zväčšovaní rozlíšenia obrázkov sme začali pociťovať značnú časovú závislosť. To sme sa pokúsili riešiť akumulovanou zmenou gradientu, ktorá čiastočne zrýchlila čas epochy ale táto zmena nebola až príliš značná. Jedným zo spôsobov, ktorý by dokázal urýchliť tréning je zvýšenie počtu workerov, tento počet sme ale nedokázali zväčšiť a náš model dokázal bežať iba pri `num_workers=0`.

CycleGan

Vstupné rozlíšenie 128x128 , 50 epoch, statický LR -> 0.0002



Consistency Loss je počítaný pre Testing množinu.

Cycle Consistency Loss $A \rightarrow B \rightarrow A$: 0.1462


Cycle Consistency Loss $B \rightarrow A \rightarrow B$: 0.1497

Average Cycle Consistency Loss: 0.1479

Môžeme vidieť že loss pre $A \rightarrow B$ a $B \rightarrow A$ sa navzájom čiastočne kopírujú s rozdielom že jeden dosahuje o niečo horší výsledok. OScilácia modelu nie je optimálna, preto sme sa rozhodli že pre ďalšie modely aplikujeme dynamicky sa znižujúci Learning Rate v pomere 97% predchádzajúceho LR za poslednú epochu.




Sample 89



Sample 69



Sample 2




CycleGAN s využitím dynamickej upravy LR po každej epoche
97% predchádzajúceho LR

Cycle Consistency Loss $A \rightarrow B \rightarrow A$: 0.1246


Cycle Consistency Loss $B \rightarrow A \rightarrow B$: 0.1423

Average Cycle Consistency Loss: 0.1335

CycleGAN dynamic LR




CycleGAN dynamic LR




Sample 89





Sample 69



Sample 2





AMSCycleGAN


Dosahoval lepšie výsledky pri malom datasete a nízkom počte epoch akonáhle sme trénovali na kompletom datasete a viacerých epochách išiel do úzadia.

Cycle Consistency Loss $A \rightarrow B \rightarrow A$: 0.1344

Cycle Consistency Loss $B \rightarrow A \rightarrow B$: 0.1473

Average Cycle Consistency Loss: 0.1408

AMS-CycleGAN Output 89



AMS-CycleGAN Output 69



AMS-CycleGAN Output 2




A $\rightarrow$ B $\rightarrow$ A (Sample 20)




Nedokáže úplne správne pracovať s týmto odteňom koní.

AMSCycleGAN



AMSCycleGAN




Wasserstein

[Cycle Loss $A \rightarrow B \rightarrow A$]: 0.1683

[Cycle Loss $B \rightarrow A \rightarrow B$]: 0.1810

[Average Cycle Loss]: 0.1747



Finalny model



CycleGan 200 Epoch dropping learning rate ->


Cycle Consistency Loss $A \rightarrow B \rightarrow A$: 0.1308

Cycle Consistency Loss $B \rightarrow A \rightarrow B$: 0.1388

Average Cycle Consistency Loss: 0.1348

Môžeme vidieť že Consistency Loss je o niečo vyšší okrem možnosti B->A->B kde došlo k poklesu.





Postupnosť kódov v projekte

Na základe progresu v projekte chronologická závislosť modelov je v tomto poradí ->

Monet_koiey.ipynb
jabka200.ipynb
Projekt_3.ipynb
Projekt_3_200.ipynb
Projekt_3_256.ipynb
Projekt_3_zebra_vylepsenia.ipynb
Wasserstein GAN.ipynb
Projekt_3_zebra_200Epoch.ipynb